B8. ConvMixer на CIFAR-10: pre-registration

Андрей Цивлин, Анна Широкая github.com/SSHwizard07/dl-b8-convmixer

1. Статья и гипотеза

Trockman, Kolter. *Patches Are All You Need?* arXiv:2201.09792.

Авторы утверждают, что сеть, которая режет картинку на патчи и дальше работает только обычными свёртками (depthwise по пространству, 1×1 по каналам), при сопоставимом числе параметров не уступает ViT и ResNet, то есть успех ViT во многом объясняется патчевым входом, а не attention.

Важно: на CIFAR-10 в статье есть только сами ConvMixer'ы (Table 3 и Table 4), сравнение с ViT и ResNet сделано только на ImageNet. Поэтому сравнение на CIFAR-10 ставим сами.

2. Ядро воспроизведения

(a) Официальный CIFAR-скрипт: ConvMixer-256/8, $k = 5$, $p = 2$, 25 эпох, у авторов 92.60%. **(b)** Строка Table 4 с той же архитектурой: 594K параметров, 95.21% (200 эпох, пайплайн timm). **(c)** Своё сравнение в одном пайплайне (25 эпох, те же аугментации и LR), сиды 0, 1, 2. Метрики: test accuracy после последней эпохи и скорость обучения (секунды на эпоху и картинки в секунду на T4):

Модель	Параметры	MAC на картинку
ConvMixer-256/8, $p = 2$, $k = 5$	0.59M	$\approx$ 0.15G
ResNet-44	0.66M	$\approx$ 0.10G
ViT: dim 128, depth 5, $p = 4$	0.68M	$\approx$ 0.05G

Критерий успеха. Сидов в статье нет, берём свою оценку разброса 0.1-0.3 п.п. (наш R0 отличается от авторов на 0.14 п.п.). (a) воспроизвелось, если среднее по 3 сидам в 92.5 ± 0.5. (b) порог 95.2 ± 1, шире из-за того, что в torchvision другие RandAugment и RandomErasing и нет mixup/cutmix. (c) ConvMixer конкурентен по точности, если отстаёт от лучшего бейзлайна не больше чем на 0.5 п.п.; по скорости сравниваем время эпохи напрямую.

3. Запуск как есть

Получилось без правок. Код locuslab/convmixer-cifar10, гиперпараметры из их README. Test 92.74%, train 94.33%, у авторов 92.60%. Colab, Tesla T4, PyTorch 2.11.0+cu130, AMP, логирование в MLflow (SQLite), около 50 с на эпоху, 21 мин на прогон. Из замечаний: FutureWarning на `torch.cuda.amp`, на работу не влияет; сид в коде не фиксируется, для следующих прогонов добавляем `--seed`; отдельной валидации нет, тест считается каждую эпоху.

4. Проверяемые недочёты

W1. Аугментации. По Table 3 без RandAug точность падает с 95.88 до 92.86. Проверяем все три модели со strong (как в R0) и weak (crop и flip) аугментацией, по 3 сида, и смотрим, как меняется разрыв между моделями.

W2. Параметры вместо compute. ConvMixer держит карту 16×16 во всех слоях и тратит в 1.5 раза больше MAC, чем ResNet-44. Считаем MAC через fvcore, меряем throughput на T4 и даём бейзлайнам столько эпох, чтобы суммарный compute совпал (ResNet около 37, ViT около 75).

W3. Нет разброса. В статье нет сидов, гиперпараметры подобраны по тесту, соседние строки Table 4 отличаются на 0.1-0.3 п.п. Всё ключевое гоняем в 3 сидах, lr для бейзлайнов подбираем на отложенных 5000 картинках из train.

5. Расширение: патч $\times$ глубина

В Table 4 патч меняется только при глубине 8. Гоняем сетку $p \in \{2, 4, 8\}$, $d \in \{4, 8, 16\}$, 25 эпох, 1 сид, и строим accuracy против MAC.

6. Ожидания

Эксперимент	Ставка
(a) 25 эпох	Воспроизведётся: 92.4-92.9%, std до 0.2 п.п.
(b) 200 эпох	94.3-95.0%, на грани порога.
(c) точность	ConvMixer впереди ResNet-44 на 0.5-2 п.п., впереди ViT на 5-10 п.п.
(c) скорость	ConvMixer самый медленный на эпоху: в 1.3-1.5 раза медленнее ResNet-44 и в 2-3 раза медленнее ViT.
W1	На weak ConvMixer теряет 2-4 п.п., ResNet 1-2 п.п., разрыв сократится минимум вдвое.
W2	При равном compute ResNet-44 догонит ConvMixer или будет в пределах 0.5 п.п.
W3	std 0.1-0.25 п.п., половина соседних строк Table 4 в пределах шума.
Патч $\times$ глубина	$p = 4$ хуже $p = 2$ на 2-3 п.п., $p = 8$ на 8-10. При $p = 8$ глубина почти не помогает: карта 4$\times$4, ядро 5 покрывает её целиком.

7. Бюджет и роли

Эксперимент	GPU-ч (T4)	Кто
R0 как есть (сделан) и ещё 2 сида ConvMixer	1	Андрей
ResNet-44 и ViT: подбор lr и 3 сида	3.5	Анна
W1 аугментации	2.5	Анна
W2 compute	2.5	Андрей
Патч $\times$ глубина	1.5	Андрей
(b) 200 эпох	2.8	Андрей
Итого	**около 14**	

Если не успеваем, выкидываем по порядку: (b), ViT в W2, лишние сиды ViT в W1, $p = 8$ в сетке. Не выкидываем ни при каких условиях: (a) и (c) на 3 сидах. Отчёт и подготовку к защите делаем вместе, каждый разбирается и в части другого.

8. Декларация LLM

Claude помогал собрать текст документа из наших заметок и лога R0 и найти нужные строки в таблицах статьи. Код, запуски и выбор экспериментов наши.